

商汤林达华访谈 · 学习文档：多模态、长程智能与空间智能

来源：36氪专访《专访商汤首席科学家林达华：多模态的涌现时刻会在一两年内到来》，2026年8月28日

文 | 李焯锋 编辑 | 张雨忻

受访者：林达华，商汤联合创始人、首席科学家

本文档定位：原文是问答体，同一议题散落在多处。本文档按论证结构重组，补出每个判断的推理链，并在末尾附与前两份文档（Kimi K3 架构领读、百度王雁鹏 Agent Infra）的横向对照。引用从简，观点均为受访者本人立场。

目录

- 0. 背景：这场对话发生在什么坐标上
- 1. 核心分歧：Coding 是智能的结果，不是智能本身
- 2. 原生多模态的真实成本：Alignment Tax
- 3. 参数规模的方法论：路径成熟度决定何时 Scale Up
- 4. 生图这条线：从"抽卡"到 Agentic Generation
- 5. 产品分层：能力的不可能三角
- 6. 资源分配的判断标准：只看两个关系
- 7. 空间智能：还没有迎来 GPT 时刻
- 8. 数据问题：缺的不是视频，是使用视频的方法
- 9. 三个拐点的时间表
- 10. 商业模式：Token 不是计价单位的终点
- 11. 给"CV 难民"的话
- 12. 与前两份文档的横向对照
- 13. 核心结论速查

0. 背景：这场对话发生在什么坐标上

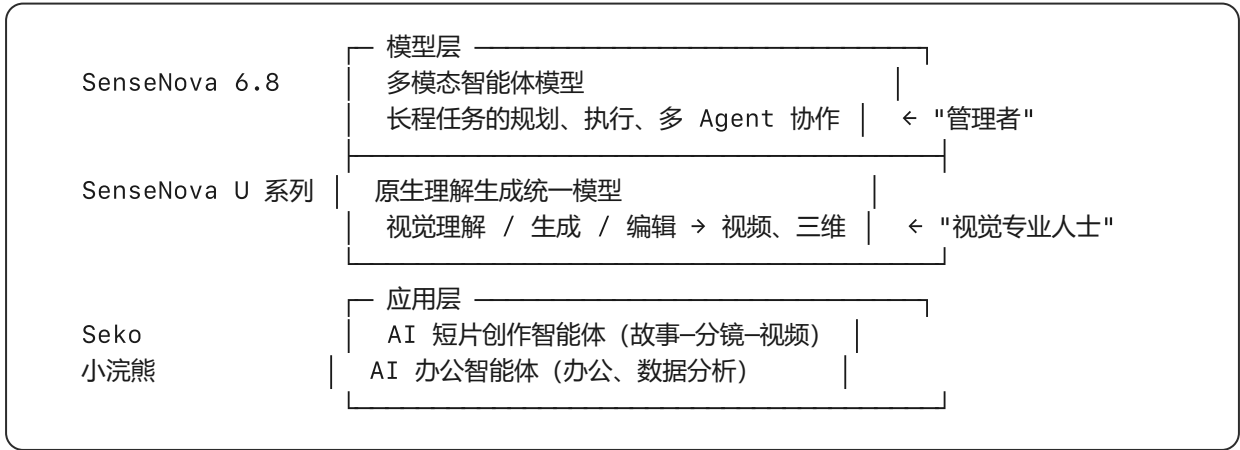
0.1 对话的三个外部参照

访谈是在一个明确的行业对照组里展开的：

参照系	立场
Coding Agent 的商业闭环	截至 7 月底，Anthropic 年化收入已超过 650 亿美元，约为 2025 年底的 7 倍。这是"多模态什么时候能拿出同样清晰的能力和商业结果"这个问题的压力来源。
梁文锋 (DeepSeek)	多模态最终会做，但不把它当作智能本身，而是看作一个"组件"（类似搜索）
黄仁勋 (NVIDIA)	发布面向机器人和自动驾驶的世界基础模型 Cosmos 3 ，把视觉推理、环境模拟、动作预测放进同一套架构——他的说法是它能理解和推理、能生成、能进入模拟闭环，甚至可以直接成为策略本身

林达华对这种分歧的定性：这不是谁对谁错的问题。每家公司面对的任务、资源和长期愿景不同，选择自然不同。

0.2 商汤的技术—产品矩阵（理解后文的前提）



U 系列的关键技术特征（与常见 VLM 的根本区别）：

	常见视觉语言模型	SenseNova U1
视觉编码器	独立的 vision encoder	拿掉
VAE（变分自编码器）	需要	拿掉
架构	语言主干 + 外挂视觉模块	一套自回归架构中联合处理语言、视觉语义和像素生成

版本节奏：

- **2026 年 4 月：** U1 发布并开源
- **约 4 个月后：** U1.5 Lite 发布，把架构从"理解 + 生成"扩展到**连续编辑**，并加强高分辨率生成与复杂指令控制

0.3 财务背景（决定了它能承受多长的技术周期）

2026 年中期业绩：

指标	数值
上半年收入	29.1 亿元，同比 +23.4%
生成式 AI 收入	23.3 亿元，占比接近八成
盈利状态	首次实现 IFRS 下盈利

这条信息在文档里不是财经花絮——它直接支撑了后文"上市公司需要不断交出阶段性结果"和"为长期技术投入留出空间"这一对张力。

1. 核心分歧：Coding 是智能的结果，不是智能本身

1.1 论证的起点

全文最凝练的一句话，用来说明 Coding 与智能上限的关系：

"没有电脑的年代，也有爱因斯坦和牛顿。我们不会因为他们不写代码，就认为他们不够聪明。"

由此展开的核心命题：

Coding 能力强，是智能水平提升的"结果"，而不是智能的"核心本质"。
智能的核心本质是：汇聚复杂信息，进行长程思考、推演、执行和修正。

1.2 为什么 Coding 反而最先跑通

林达华没有否认 Coding 的地位，而是解释了它的"先发"是数据条件决定的，而非本质地位决定的：

Coding 是目前数据条件最成熟的、体现长程思考能力的载体。

四个条件同时具备：

条件	具体内容
过程数据充足	GitHub 上有大量过程数据
可执行	代码可以运行
反馈确定	测试用例能提供确定的反馈信号
市场成熟	背后有成熟的软件工程市场

所以它最早走通了训练闭环和商业闭环。这是一个关于"为什么是 Coding 先跑出来"的充分解释，而不是关于"Coding 更接近智能本质"的证明——这是本节论证的关键转折。

1.3 原生多模态是不是必要条件

限定性回答：

- 如果模型只写代码：多模态未必是必要条件。
- 一旦任务从 **Coding** 走向更广泛的行业和真实世界：很多场景就离不开它。

商汤的任务清单决定了它的选择：办公、医疗、零售、机器人、世界模型——都不可能缺少视觉信号。

商汤很早的判断是：视觉和语言的联合建模，是人工智能进入真实行业和物理世界的基础。

1.4 一个反击"Coding 不需要视觉"的例子

即使是做前端开发，模型写完代码也要把页面渲染出来，看看好不好看、有没有明显错误——这同样需要视觉能力。

1.5 商汤对 Coding 的实际立场（避免误读）

需要注意，他的表述是有分寸的，不是"不做 Coding"：

- 商汤也做 **Coding**，把编程能力视为模型的重要基础能力；
- 但不会把复杂软件工程作为唯一/主要的主攻方向。

2. 原生多模态的真实成本：Alignment Tax

提问背景：一些做 MLLM 和原生多模态的研究者反映，加入视觉数据会显著增加预训练和后训练难度，配比处理不好还会导致语言、数学、推理能力退化。

2.1 先把"推理成本"这个误解排除掉

如果只是在语言模型上接一个视觉编码器，推理端多出来的计算，相较于数百 B 甚至 1T 参数的语言主干，其实微不足道。

真正困难的是训练。

2.2 困难之一：数据配比与 Alignment Tax（对齐代价）

问题定义：模型增加视觉能力就要加入相应数据，同时又要避免原有的语言、数学和推理能力退化。这个代价就是 **Alignment Tax**。

为什么它比想象中贵——两个容易被低估的点：

1. 它不是调一个比例那么简单：不只是把比例从 1:9 调成 2:8，还要做大量对照实验；
2. 它不是一次性成本：模型每次升级，配比都可能需要重新调整。

2.3 困难之二：强化学习

引入新模态之后：

- 训练目标和技术方案都会变复杂；
- 更根本的是——给视觉相关任务建立反馈信号本身，还是一个开放问题。

对照第 1.2 节：Coding 之所以先跑通，正是因为“测试用例提供确定反馈”。视觉任务恰恰缺的就是这个。这两节其实是同一个论证的一体两面。

2.4 最贵的成本项不是算力，是时间

这是本节最值得记的一句：

最贵的往往不是最后一轮大规模训练，而是前期探索方法的时间。
对模型公司来说，问题未必是付不起钱，而是多做一轮实验，模型就可能比竞争对手慢一个月。

2.5 由此推出的策略：先用 8B 轻量模型迭代

理解和生成统一这条路径还没有完全收敛，先把架构、数据配比和训练方案跑稳，再扩大规模，效率反而更高。

3. 参数规模的方法论：路径成熟度决定何时 Scale Up

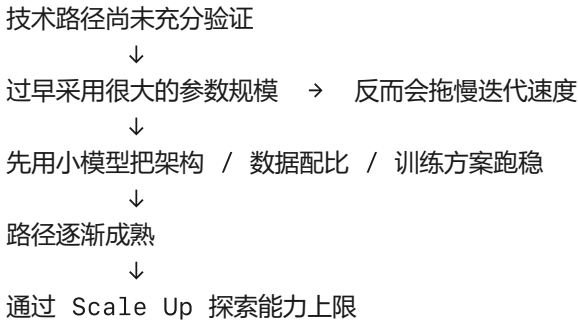
这一节回应的是“要不要冲 1T 参数模型”的问题，是全文方法论最清晰的一段。

3.1 内部结论

商汤内部讨论过要不要冲 1T 参数模型，结论是：

- 在合适的时候会做 1T 和更大的模型；
- 但一定要基于有革新性的架构和技术来推进，而不是简单扩大规模去做同质化竞争。

3.2 判断规则：一条随路径成熟度切换的曲线



商汤当前两条线的不同位置：

模型线	所处阶段
多模态智能体模型（SenseNova 6.8）	已进入 Scale Up 阶段
理解与生成统一（U 系列）	架构和训练范式上仍有一系列问题需要探索

3.3 底层的竞争观：认知领先 > 参数领先

参数大小只是具体的技术选择。更重要的是在认定的方向上走得足够快，让自身的认知走在前列。

当前大模型竞争异常激烈，模型公司的认知是否走到前面、迭代速度是否足够快，是非常重要的、甚至成败攸关的。

不希望为了尽快把规模做大，而延缓对真正问题的探索。

4. 生图这条线：从"抽卡"到 Agentic Generation

4.1 U1 的用户价值：先理解，再决定怎么生成

对用户来说，最直接的变化是：模型先理解内容，再决定怎么生成。

面对几段复杂信息，它要判断哪些内容重要，再安排结构、版式和视觉表达。

为什么切入点选"信息图"：因为信息图正好需要把理解、推理和生成连起来——它是这条技术路线最自然的验证场景。

4.2 为什么先放下空间智能

U 系列更长期的目标是空间智能和物理智能。商汤也曾考虑把空间智能和生图一起做，但：

模型每增加一种能力，训练复杂度都会明显上升。

所以选择先把更复杂的空间智能放一放，让 U1 先把理解与生成统一这条路走通，建立起"如何让语言和视觉元素在一个表征空间中融合"的技术认知。

4.3 一个上市公司的现实约束

做长期技术不能闷着头三年，什么阶段性成果都不拿出来。商汤是一家上市公司，需要不断交出用户有感知、对行业也有价值的结果。

生图是这条路最先解锁的能力，但不是终点。

4.4 U1 → U1.5 的三级递进（一个非常具体的产品迭代样本）

这段值得完整记录，因为它展示了"能力—体验"之间的层层剥离：

第一层：文字要对

U1 推出后，在实际使用中发现文字生成和局部细节还有提升空间。从 4 月到 6 月连续迭代信息图版本，把文字逐步修对。

第二层：审美要有

后来发现，字即使全对了，图也可能像学生做的 PPT，没有设计感。所以请真正的设计师参与，把审美这一课补上。

一个重要的判断：

审美和逻辑能力是两件事，Coding 和美感也是两件事。模型再强，也不会自动产生美感。

第三层：能连续编辑

文字准确、画面好看，解决的仍然只是单次生成质量。

真实设计不会生成一次就结束——完整的构图和修改要求可能有一两千字。模型既要理解这些约束，也要只改指定区域，尽量不动其他部分。

4.5 "抽卡" vs "持续编辑"

	一次性生成（抽卡）	持续编辑
失败模式	连续生成五张图，可能分别错在五个地方，没有一张能用	保留已经正确的部分
用户动作	重抽	哪里有问题就改哪里

4.6 Agentic Generation（智能体式生成）

持续编辑是一项基础能力。以此为枢纽，就能把"理解要求—生成内容—反复修改"连成一个闭环，这就是商汤所说的 **Agentic Generation**。
模型围绕同一份作品持续迭代，直到能够交付。

5. 产品分层：能力的不可能三角

5.1 不可能三角

能力广度 × 专业深度 × 成本 —— 这三者构成一个不可能三角。
一个又广又深的超级模型当然可以做，但一定很大、很贵。

5.2 Lite 与 Pro：两类需求，不是两个档次

提问背景：姚顺雨（腾讯）曾提出，用户愿意为最强的模型付费；企业判断性价比也要先看性能，有时模型更贵，却可能因为一次把事情做对而更省钱。

林达华的前置条件：

模型首先要达到用户真正能用的水平，价格才有讨论的意义。

	U1.5 Lite	U1 Pro
参数	8B，开源	更大
定位	效率与性价比，适合大量日常任务	追求能力上限，交付专业级效果
成本	低	高得多
缺陷特征	出现细节瑕疵的概率更高，但容易修改，不必重新抽卡	—
类比	轻便相机	专业单反

注意 Lite 的缺陷描述与 4.5 节的"持续编辑"是咬合的：正因为有了连续编辑能力，"瑕疵率更高"才不再是致命问题。

5.3 企业该用一个超级模型还是一支模型团队

模型先要有完整的基本能力，再术业有专攻。

企业也不会每个岗位都雇一个"超人"，现实的做法还是让不同专业的模型组成团队——当然，这里每个模型仍然要有健全的基本智能。

商汤矩阵内部的分工：

角色	模型	职责
管理者	SenseNova 6.8	长程任务 + 多个专业智能体的协作；这个智能体也需要有"眼睛"来看懂图像并决定下一步行动
视觉领域的专业人士	U 系列	精细视觉感知、可控生成、空间智能

那句"管理者也需要有眼睛"很关键——它说明在商汤的设计里，视觉不是外挂给专业模型的，调度层本身就需要视觉。

5.4 Seko 的分工哲学：掌握流程，而非掌握渲染

提问背景：Seko 能完成视频创作，也可以接入 Seedance 等专用模型。

林达华的划分：

- 交给别人的：最终的视频渲染可以调用 Seedance 等专用模型。理由是——视频画质很大程度上取决于高质量数据和资源投入。
- 自己掌握的：故事怎么展开、分镜如何生成、看完效果以后怎样调整——这套创作和迭代的闭环。

理由：

这个创作流程才是真正体现创作者智能水平的地方。

商汤更关注的是让模型理解创作意图，判断哪里需要调整，再把理解、生成和修改连起来——这与 4.6 节的 Agentic Generation 是同一个内核在视频场景的复用。

6. 资源分配的判断标准：只看两个关系

提问：生图、生视频、三维和空间智能都要持续投入，资源有限时用什么标准聚焦？

6.1 两个关系

这是全文方法论密度最高的一段：

- 我们真正聚焦的是两个关系：
1. 语言智能能不能影响视觉想象和生成；
 2. 视觉生成和想象，又能不能反过来影响推理。

投入上重点关注：哪些事情可以提升我们对上述两个问题的认知。

生图、视频和三维看起来是不同方向，底层都在处理这两个关系。

6.2 由此推出的"不做什么"

因为标准是"提升对这两个关系的认知"，而不是"把指标做到极致"，所以：

方向	态度
视频	不会把电影级画质作为最主要的竞争点
人像生成	会继续做，主要是保证生成质量，但不会成为最核心的方向

6.3 场景选择也服从同一个标准

业务	选定的重点场景	为什么选它
生成	信息图	需要真正的智能来判断如何在有限的画面中有效组织和传达信息
办公	数据分析和预测	对智能水平的考验很强，可以牵引智能上限的摸高

这是一个统一的选择逻辑：选那些"做好了就等于智能上限提高了"的场景，而不是选那些"做好了只是指标好看"的场景。

6.4 一句关于竞争节奏的自陈

所有人都在卷 Coding 时，我们反而可以按自己的节奏做事。如果所有人都转去做空间智能，我们的压力可能会更大一点。

7. 空间智能：还没有迎来 GPT 时刻

7.1 当前状态：能用但不能泛化

具体场景里能用的东西已经很多，只是还不能泛化。
给定一个场景，今天的 VLA（视觉—语言—动作模型）或 WAM（世界动作模型）可以做得很专业，但换一个场景，模型未必还有基本判断。

7.2 什么才算"GPT 时刻"：广 × 深

真正的 GPT 时刻，需要同时做到广和深：

维度	含义
广	换到很多场景都能理解
深	能够持续完成长程思考和行动

一个额外的必要条件：

- 空间能力还要和复杂逻辑结合，否则任务走到一半突然不会想了，依然很难商业化。
- 注意这里与第 1 节的呼应：“深”的定义就是长程思考——他对空间智能的评判标准，和他对智能本质的定义是同一套。

7.3 时间判断

- 如果要看到具备一定泛化能力的系统，我觉得还需要 1—2 年。
- 模型的能力会一点点提高，不会在某一天突然完成切换。

8. 数据问题：缺的不是视频，是使用视频的方法

8.1 先做一个概念区分（很重要）

概念	定义
世界模型	要学习世界及其物理规律
空间智能	关注的是人怎样理解空间、在空间中思考和行动

8.2 判断：不缺数据，缺的是使用方法

- 至少对空间智能来说，我不认为世界上缺视频。公开视频和第一人称视频都非常多，商汤的生态企业也在做第一人称数据采集。
- 真正的问题是，这些数据还没有被充分利用。

8.3 数据要分层使用

对标语言模型的训练分层：

阶段	做什么
预训练	广泛吸收素材
中期训练	加入具体领域的任务和推理过程
后训练	面向具体任务调整

8.4 当前的根本缺失：用视频训生成，没有用视频训智能

- 现在大家主要用视频训练生成模型，让它学习“画面长什么样、下一帧怎样变化”，却没有充分利用视频提升智能。

那个电影表情的例子（本文最好的一个例子）：

- 比如电影里，一个人看到某件事后突然露出惊恐的表情。

模型不仅要"看见"这个表情，还要理解他"为什么"惊恐、它和正在发生的事情有什么关系。这才是理解。

8.5 因此要做两件事

1. 继续采集适合空间智能的视频；
2. 围绕视频提出正确的问题、建立事件之间的关联。

后者才是目前还没有规模化做好的事情。

8.6 三维的优先级可能高于视频

从空间智能的目标看，三维的优先级甚至可能高于视频——因为空间智能的本质就是理解三维世界，并且能在三维空间中行动和交互。

从图片延伸出去的技术关系：

- 连续编辑和反馈循环的基本原理是相通的；
- 但进入视频和三维以后，数据形态更复杂，也会遇到新的问题。

关于 U2 的预告：

U2 也会加入更多空间智能元素，对三维空间的建模和理解会进一步加强，不会只是把静态图片延长成视频。

9. 三个拐点的时间表

9.1 先重新定义"拐点"

Coding 并没有突然比过去强几个数量级，只是能力积累到了一个阶段，大家开始觉得它真的好用了。

这句话把"拐点"从一个技术事件重新定义为一个感知事件——是全文对"涌现"这个词最克制的一次处理。

9.2 三个拐点对比

领域	时间判断	拐点的具体标志	影响深度
设计	已经不远，"可以按月来计算"	进入真实工作流——比如直接生成能够在 Figma 等工具里继续使用的内容	中
多模态整体	未来 1—2 年跨过类似 Code Agent 的节点	形态可能不是生图或视频工具，但内核是视觉、语言、推理和行动的結合	大
空间与视觉推理	会来得更晚	—	影响也会更深

设计拐点为什么"靠数据和产品功能就能解决":

模型的可控性和视觉质量不断提高，下一步是进入真实工作流。从"好看"到"好用"，很多问题靠更好的数据和产品功能就能解决。

空间智能拐点为什么影响更深:

没有具备空间智能的大脑，机器人只能在固定场景里完成固定动作，很难在复杂物理空间中独立完成长程任务。

10. 商业模式: Token 不是计价单位的终点

10.1 价格战的必然与它的天花板

提问: 生图和视频的调用价格持续下降，多模态会走向价格战吗?

前半段承认:

如果大家处在同一个能力水平，用户当然会选择更便宜的模型。

后半段是关键:

但只围绕 Token 竞争，利润会被压得很低，模型最后真会变成水电煤。

我认同人工智能会成为水电煤，但水电煤不是这个时代最赚钱的行业。

10.2 计价单位的类比论证

律师不是按判决书字数收费，医生也不是按病历字数收费。把官司打赢、把病治好，用户才愿意为结果付费。

智能不是论斤卖的。Token 只是一种计量单位，最终要看你解决的问题值不值钱。

10.3 可能的收费形态

- 按任务收费
- 按最终交付收费
- 由 AI 和客户共同完成工作，再对结果分成

用户不关心模型消耗了 1M 还是 100M Tokens，只关心事情有没有做成。

10.4 与之配套的商业验证路径

市场最终还是要看这条路线能不能产生客户和收入。

商汤需要通过小浣熊等产品的用户增长、复购和付费，来证明多模态在商业上是成立的——而不是只靠发布一个更大的模型。

11. 给"CV 难民"的话

提问背景: Coding 率先跑出商业回报后，一些多模态方向的研究者自称"CV 难民"。

11.1 承认焦虑的合理性

Coding 热，人才价格自然更高，大家都会受到影响。但不同方向跑通商业化，本来就有先有后。

11.2 一个被遗忘的历史对照

这个类比很有说服力，因为它把今天的处境反过来放了一遍：

2022 年以前，自然语言处理也没有今天这样的商业价值。

那时做智能客服很苦，需要大量定制，有人反而觉得不如回去做计算机视觉——因为人脸识别等场景至少已经能够规模化商用。

今天只是 **Coding** 先走到了一个商业前景非常明确的位置。

11.3 买股票的类比

现在 **Coding** 是涨得最快的一只，但不代表每个人都要把所有资金、甚至把人生都押在上面。

人工智能改变的不会只有 Coding，每个人还是要根据自己的积累和判断，选择真正相信的东西。

11.4 但是——不能重复过去的路线

这是他给多模态从业者最硬的一句忠告：

坦率地说，传统 **VLM**（视觉语言模型）的基本范式已经走到尽头了。

如果今天谈多模态，仍然只是做 **VQA**（视觉问答）、回答“图片里有什么”，无论技术价值还是商业价值都不会很大。

总结性表态：

多模态不是伪需求，但要问对问题。

至于每家公司和每个从业者选择 Coding 还是多模态，并没有天然的优劣之分。重要的是根据自己的积累和判断，选择真正相信的方向，而不是简单跟风。

11.5 对 Coding 的最终评价（一个相当大方的定性）

现阶段，**Coding** 的意义超越了 **Coding** 本身。

它让大家看到，人工智能真的能够做事情、创造商业价值，而不只是写诗作画。这给整个行业提供了很大的信心。

12. 与前两份文档的横向对照

这一节是本文档的附加分析，不是原文内容。三份材料分别来自模型架构层（孙宇韬）、基础设施层（王雁鹏）、模型形态层（林达华），恰好构成一个纵切面。

12.1 三者的位置

	孙宇韬（Kimi K3 领读）	王雁鹏（百度 Agent Infra）	林达华（商汤多模态）
视角	模型架构与预训练	算力、运行时、产业格局	智能形态与能力边界
关心的问题	怎么把 token 算得更便宜	怎么让 agent 跑得起来、跑得住	智能应该长成什么样
方向	往下看（芯片、kernel）	上下都看（芯片 ↔ agent OS）	往上看（任务、物理世界）

12.2 三处高度一致的判断

① 都否认"阶跃式创新"

谁	说法
孙宇韬	科学研究不存在阶跃性提升，只是大家习惯把渐进提升的某些节点称为 milestone
林达华	Coding 并没有突然比过去强几个数量级，只是积累到一个阶段大家觉得好用了；能力不会在某一天突然完成切换
王雁鹏	Agent 能力还没到蓬勃发展的临界点，是逐步逼近的

三个人分别从架构、能力、产业三个角度，说了同一件事。

② 都认为 Token 指标正在失效

谁	说法
王雁鹏	Token 很快就被玩坏了——拿 token 干没价值的事；不能利用恐慌心理让大家烧 token；所以提出 DAA（Daily Active Agents）
林达华	律师不按判决书字数收费；只围绕 token 竞争利润会被压得很低；应按任务、按交付、甚至按结果分成收费

两人从供给侧（云厂商）和需求侧（模型/应用方）走到了同一个结论。这是三份材料里最强的一处交叉验证。

③ 都认为"通用大脑 + 专业分工"是终局形态

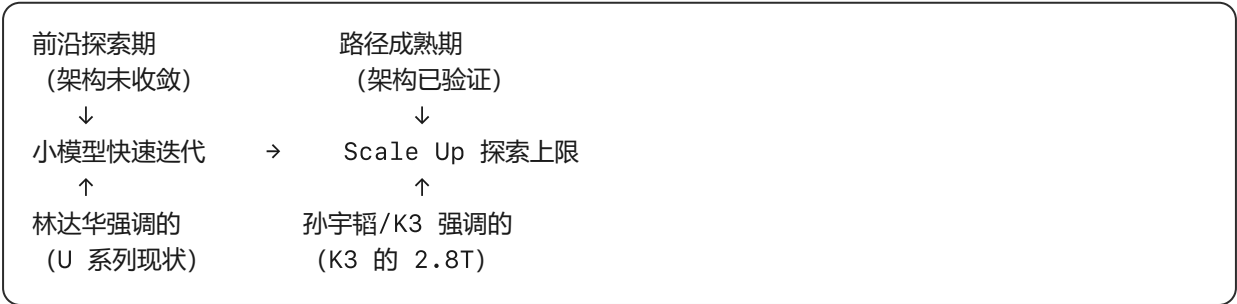
谁	说法
王雁鹏	模型会是 OS、是大脑，但每项具体工作的 know-how、workflow、记忆、数据不会被完全吸收 → 所以 agent 会越来越多
林达华	能力广度 × 专业深度 × 成本的不可能三角 → 企业不会每个岗位雇"超人"，而是让不同专业的模型组成团队

12.3 一处表面矛盾，实则互补

关于"要不要把模型做大"：

谁	立场
孙宇韬 / K3	有 size 才有智能；K3 把激活做到 104B "是要一定魄力的"；模型参数量是决定性能最本质的因素
林达华	路径未验证时过早采用大参数规模，反而会拖慢迭代速度；反对简单扩大规模的同质化竞争

看似对立，实则说的是曲线的两段：



值得注意的是，林达华自己也承认商汤的多模态智能体模型"已经进入 **Scale Up** 阶段"——他反对的不是 scale，而是在路径未成熟时用 **scale** 替代认知。而孙宇韬同样强调"扩大模型 **size** 本身不是创新，把它做 **work** 中间才有创新"。

两人的真实分歧其实很小：都认为"有效的 **scaling**"才算数。

12.4 三人对"下一步去哪"的判断惊人地趋同

谁	对现有范式的判断	指向
孙宇韬	大模型可能没有太本质的创新了，后面都是改良性进步 → 个人转向世界模型	物理世界
林达华	传统 VLM 的基本范式已经走到尽头 → 原生多模态、空间智能与物理智能	物理世界
王雁鹏	纯语言 scope 内"问题不大"；如果定义 AGI 是具身、是真实物理世界交互，gap 就更大	物理世界

三个处在完全不同层级的从业者，都把"下一个真正困难的问题"指向了同一个方向。这可能是这三份材料放在一起最值得注意的一件事。

12.5 一处有趣的张力：视觉反馈信号

- 林达华：视觉任务的反馈信号本身还是一个开放问题，这是原生多模态 RL 最难的地方；
- 孙宇韬：Kimi K3 的 vision encoder 选择 **from scratch** 而非用 **SigLIP** 初始化，理由之一是优化器兼容性和 gradient norm 稳定性。

两者都在说"视觉加进来之后，训练变得难以控制"——只是一个从目标函数角度说，一个从优化动力学角度说。

13. 核心结论速查

1. **Coding 能力强是智能提升的结果，不是智能的本质。** 智能的本质是汇聚复杂信息、进行长程思考、推演、执行和修正。
2. **Coding 先跑通是数据条件决定的：** GitHub 过程数据 + 可运行 + 测试用例给确定反馈 + 成熟的软件工程市场，四条同时具备。
3. **原生多模态贵在训练不在推理。** 推理端多出来的算力相对数百 B / 1T 主干微不足道。
4. **Alignment Tax 的真实形态：** 不是"把 1:9 调成 2:8"，而是大量对照实验 + 每次模型升级都可能要重调。
5. **最贵的是时间不是钱——** 最贵的不是最后一轮大训练，而是前期探索方法的时间；多做一轮实验就可能比对手慢一个月。
6. **视觉任务的反馈信号本身仍是开放问题，** 这是多模态 RL 的根本难点，也正是 Coding 的相对优势所在。
7. **规模由路径成熟度决定：** 路径未验证时过早 scale up 会拖慢迭代；路径成熟时才通过 Scale Up 探索上限。认知领先比参数领先重要。
8. **审美和逻辑是两件事——** 模型再强也不会自动产生美感，商汤是请设计师参与才补上这一课。
9. **从抽卡到持续编辑：** 一次性生成的失败模式是"五张图错在五个地方"；持续编辑让用户保留正确部分、只改问题处。以此为枢纽形成的闭环叫 **Agentic Generation**。

10. **不可能三角**：能力广度 × 专业深度 × 成本。终局是专业模型组成团队，而不是一个又广又深的超级模型。
11. **调度层本身也需要视觉**——多模态智能体作为"管理者"，同样需要"眼睛"来看懂图像并决定下一步。
12. **资源分配只看两个关系**：语言智能能否影响视觉想象与生成；视觉生成与想象能否反过来影响推理。生图/视频/三维底层都在处理这两个关系。
13. **选场景的标准是"能否牵引智能上限"**——选信息图（有限画面里组织和传达信息）、选数据分析与预测，而不是选指标好看的场景。
14. **空间智能的 GPT 时刻 = 广 × 深**，且空间能力必须与复杂逻辑结合，否则任务走到一半就"不会想了"。判断还需 **1—2 年**。
15. **不缺视频，缺的是使用视频的方法**。现在只用视频训生成模型（画面长什么样、下一帧怎么变），没有用视频提升智能——看见惊恐的表情不够，要理解他为什么惊恐。
16. **三维的优先级可能高于视频**，因为空间智能的本质就是理解三维世界并在其中行动交互。U2 不会只是"把静态图片延长成视频"。
17. **设计拐点按月计算**（标志是进入 Figma 这样的真实工作流），**空间与视觉推理拐点更晚但影响更深**。
18. **Token 只是计量单位**：律师不按判决书字数收费。AI 会成为水电煤，但水电煤不是这个时代最赚钱的行业。
19. **传统 VLM 的基本范式已经走到尽头**——今天还只做 VQA，技术价值和商业价值都不大。**多模态不是伪需求，但要问对问题**。
20. **方向没有天然优劣**。2022 年前 NLP 也曾是"不如回去做 CV"的那一个。Coding 是现在涨得最快的一只股票，但不必把人生押上去。