

梁文锋投资者交流会 · 整理稿

来源说明：音频《deepseek 0520.m4a》，总时长约 3 小时 44 分钟，5 月 20 日录音，2026-07-16 整理。原稿由语音识别自动转写并经 AI 整理，未区分说话人，个别专有名词与数字可能存在识别误差，请以原录音为准。

会议主持人提醒：梁文锋讲了很多较敏感的信息（包括卡量等数字），请勿外传，勿录屏对外分享。

本整理稿按主题重新归类，前半部分为梁文锋主讲内容，后半部分为逐题问答，末尾附关键数字速览。原文所有信息点均已保留。

第一部分：主讲内容

一、公司初衷与愿景

- 创办公司的初衷不是赚钱、上市、走向资本市场。最开始的几十个人完全没这么想过——“如果他这么想，他就不会来”。
- 总体是怀着对这个世界非常大的善意来做这件事，认为它对人类有用，是一个金钱以外的事情。
- 后来发现利益非常大之后，会有其他诱惑，但那是另外的事情；出发的初衷、愿景，以及保持到现在的愿景，**不是按商业利益最大化的方式来做**的。
- 大约二十年前，梁文锋在管理上最崇拜杰克·韦尔奇（GE 前 CEO）。现在回看，他说的大部分东西可能都不对了，但最重要的一点说对了：**一个公司最重要的是它的愿景**。管理一个大公司靠的不是规章制度，靠的是愿景。
- 愿景不是挂在墙上的标语，愿景是你**怎么做**，不是怎么说，是实际运行方式。
- 公司如何管理、组织这么多人？**“我们没有组织，就是愿景驱动的，靠一个愿景来组织。”**这有好处也有坏处，未来会想办法扬长避短，但这是公司的特色。
- 不以 KPI 方式运作，没有考核，只有愿景。
- 这个愿景**不成文**，没有写出来过任何东西。它存在于做事的方法、对待世界的态度里。每个人对愿景的理解可能不一样，但大方向一致。
- “这个愿景是真的，不是编出来的，我们是真的这么想、真的这么做的。否则你没法解释我们的很多事情。”

二、开源战略

为什么坚持开源：

- 愿景本身就要求开源；没有这个愿景，没法把人组织起来。
- 对比：智谱也开源，但智谱的开源“有一种被迫的感觉”，不是本意；对 DeepSeek 来讲，开源就是本意。
- 开源这件事一开始就想得非常清楚：第一是愿景；第二，**要把 AI 在商业上做成，开源是有好处的**。

开源与商业化为何不冲突（AI 与历史上的软件不同）：

- 历史上开源与商业化有冲突：一个软件公司市场一年可能就几十亿美金，一开源可能只剩几千万或几亿美金。
- 但 AI 足够大——最终可能占人类社会 GDP 的 10%（举例）。这么大的事情**不可能一个人独占**，一定得跟别人分享，否则活不下来。想独占利益，一定会被历史抛弃，这是客观规律、是一种历史观。
- 不开源也无法独占市场——理论上就不符合客观事实，一定会遇到很多阻力，一定有其他方法阻止你实现目标。
- 因此需要一套机制**确保自己获得的利益是有限的**，才有可能做成。"你越克制，越有可能做成。"到目前为止这个逻辑是被印证的、能解释得通的——否则无法解释为什么能做成：没有武器、起点非常低、资源非常少。

"平凡人"叙事：

- "我们并没有比别人有钱，人员也没有比其他公司更好。"两年前成立公司时，没有很多钱、没有很多卡、没有知名度、没有号召力，"就是一群非常平凡的人"。
- 喜欢的叙事是"**一群平凡的人做出了不平凡的事情**"，而不是一群天才做出不平凡的事情。这跟克制、跟愿景一脉相承。
- 梁文锋自述："我自己也就是一个大学毕业的学生，也不是最顶级的那个学校毕业的。"

开源的商业分析：

- 看不到闭源有什么必然好处。"字节的模型是闭源的，它有什么好处？我看不到。"最强的模型可能也会开源。
- 即便模型开源、把所有东西都告诉别人，**使用门槛依然非常高**：要用起来很难；要把成本做得很低更是难上加难。不是每家公司都有意愿和能力组织人力达到这个目标。
- 大公司有管理上和物理上的制约，很难组织；创业公司太小又没有力量。**这是属于 DeepSeek 这个规模公司的甜区 (sweet point)**。
- 定价按十个月回本收费，就能**让独立部署的第三方无利可图**——第三方做不到这个成本。所以开源并不影响收入。
- 前提是只赚约六倍利润（十个月回本对应约六倍利润）。如果想赚一百倍利润，开源确实会影响——因为第三方部署成本可能只有二十倍，比你低。
- 这个模式**长期可持续**，打算一直这么做。这也是克制、让利的一部分，让公司在技术前沿有更多机会，做成 AGI 的概率更大，"我们更从容"。
- "我们根本都不用加班，因为就没那么难。"外面看起来选了 hard 模式（做研究、做最难的事），但因为在别的地方舍弃了很多，反而做得非常轻松。
- 六倍利润看起来高其实不高——在当前 AI 效率下这就是合理利润；未来可能降到四倍、三倍，再往下不太可能，但仍会有很大利润。
- 卖 API 本身没有那么大吸引力，但至少说明开源与商业付费没有冲突。

不担心他人部署竞争：

- "一点都不担心"别人部署 DeepSeek 模型来竞争，反而希望他们能部署起来，会尽可能给开源社区提供帮助。

- 只担心对方部署不起来、细节没做对导致效果差或成本高。市场足够大。
- 去年曾被问：开源后腾讯这种流量大户部署开源模型，会不会把 C 端用户都抢走？**事实证明不会**，有很多原因。去年一整年 C 端基本开源，C 端服务没有看到冲突。
- **开源模型与自己部署的模型完全一样**，不会开源一个差一点的版本、自己用更好的版本。

三、定价逻辑与"合理利润"

- API 定价逻辑：**到市场上买一批设备，十个月收回成本**，就是合理利润。财务上服务器按三年或五年摊销，但商业上十个月回本"我们觉得够了"。V3.2 Flash 与其他产品都是按十个月收回设备成本定价。
- 这不是利润最大化定价。若要利润最大化应把价格设更高——在这个价格区间**用户需求没有弹性**：价格翻倍，token 消耗量区别不大，总收入接近翻倍。
- 讲了一个故事：DDCP（模型）一开始担心需求太多把价格定得比较高，团队里大家不太高兴；后来把价格降到四分之一，大家就很开心，**降价时公司群里很多人欢呼**。
- "这是我们花这么多精力、这么用心把模型做好的目的：非常便宜、效果非常好、让大家都能充分地用。"这是动力、愿景，也是公司内部凝聚的共识。
- 对竞争对手来说降价一定不是好事——收入、ARR 会掉一半，他们不会欢呼。这是 DeepSeek 不一样的地方。
- 十个月回本，公司内部商业上已非常满意；对外部，这个价格大家开心，公司与社会、所有人双赢。
- 有人在屏幕留言说"十个月回本利润太高"。回应：确实还有降价空间，模型优化上也还有空间，整体降价空间比较大。**但这个成本只有 DeepSeek 自己做得到**——阿里、腾讯没有这些优化，成本应比这个高好几倍。
- 为什么不继续降价：因为需求没有弹性——再降价需求不会更多，这个价格所有人都用得起、都满意，不会因价格贵而不用。再降价公司不会有更多收入，对社会也没有更多价值、幸福感不会增加很多。

四、克制作为战略

- 定价不以公司收入最高或利润最高为出发点，这是克制的一部分。短期看价格高一点收入多一点，长期还真不好说。
- **"克制是一种战略"**：有时舍弃一些，换更多其他东西。开源也可视为让利/压力的一部分。
- 让利的好处：对内，大家高兴、员工有成就感、公司有凝聚力；对外，社会高兴、同行和普通人高兴。长远上，**克制能增加做成 AGI 的概率**。
- 毫不怀疑 AGI 会有非常大的商业价值。在此基础上，优先考虑的不是怎么多拿份额，而是**怎么增加做成的概率**。

克制的具体体现——不抢用户、不急变现：

- 去年春节用户突然很多，但没有去追求留存这些用户、拿用户变现、抢商业利益。
- 没有想做下一个超级 App、跟谁竞争、做成下一个字节或腾讯——"完全没有这样的想法"。可以这么做（去年砸大笔钱跟字节抢用户在商业上是行得通的打法），但选择了非常克制的做法。
- **芝麻与西瓜的比喻**：不跟人争前面的芝麻，因为后面还有西瓜。"可能这个芝麻比较大，但后面的 AI（机会）面前，前面都不算大。"现在看来，去年没在 C 端发力可能是对的。

- 后面的 AGI 机会永远是非常大的，甚至不用考虑到时候占什么位置、商业模式是什么——只要有那么大的商业机会，一定有办法。
- 前面的芝麻"随手捡一点"，不会停下来当重要事情做。去年的 C 端日活是小事，但也捡了：用较低的成本维持用户使用，因为以后可能有用（现在是纯成本支出，不知道有什么用，但既然随手能拿到就顺手拿）。
- 今年 API/AI 方面的 ARR 收入也有机会：如果需求继续扩大、能买到更多显卡，**ARR 做到几个亿美金很有可能**；如果能做到十亿美金，公司现金流基本能回正，能 cover 研发费用和所有费用。但没有把它当优先事项。
- 去年的 C 端、今年的 B 端，要做、要做好，但不是目标；公司大部分人不认为这是与 AGI 同等重要的问题。

五、AGI 技术路线图

长期目标就是 **AGI**。每个人对 AGI 定义不一定一样，但不妨碍把 AGI 当目标。从技术路线上看，AGI 路线图是比较清晰的。

当前 AI 的能力边界：

- 如果能把问题描述清楚、给它完整的上下文和指令，当前这代 AI 已经超过人类。但这个前提很难达到。
- 例子：今天开会，大家有几十年的上下文，这是 AI 不具备的。AI 能做到的是在局限的上下文里比人做得更好。
- AI 还替代不了人类，差的是**持续学习**。人可以持续学习：新员工花两个月熟悉公司环境和工作就能上手，你说"叫小王过来"他知道小王是谁；AI 没有这两个月的学习，你得告诉它小王是谁、什么职务、在哪里、怎么找、注意什么——**你不可能给 AI 所有的上下文，也不现实**。
- 如果 AI 具有持续学习能力，像员工一样到公司学习两个月，就可以替代天下的人了。"我们离下一步还差一个学习去学习。"

阶梯论：

- AI 发展是一个阶梯。去年走的阶梯是 **CoT（思维链）**——通过自己思考让智能达到更高水平、上限更高。
- 今年的阶梯是 **Agent**——用 Agent 的方式能力范围更大、智能上限更高。
- 为什么是阶梯：后面每一步都基于前面的基础。Agent 要用到 CoT，CoT 要用到语言模型，**没有一步是白走的**。
- 每个阶梯都会走完：CoT 到上限后，在做奥数题、写程序上已超过最顶尖人类，但停在那里，没有到达 AGI；Agent 也一样，把能解决的问题解决完后仍不能替代员工，就到了能力上限。
- **Agent 之后要解决的是持续学习**：怎么让模型可以像人一样做比较长时间的持续学习，而不是靠一次很强的训练。这与完成任务等是同一个问题、相关的问题。站在 Agent 这个位置，能看到的下一个瓶颈就是持续学习——相对明确，必须跨过去，一定有办法跨过去，但需要时间。

奇点与具身：

- 持续学习之后，可能来到一个**奇点**：模型能做人类能做的所有事情，能自己研究、开发自己的下一个版本，实现自我迭代。

- 但它并不是真正的奇点——是一个渐进的、比较长的渐变过程，不是突变。只是习惯上（早期预言家认为）它是奇点，其实是连续的过程。
- 这一步走完之后**才是具身智能**。到具身智能之后，AI 走进现实世界，可以做家务、可以养老。
- 推测的时间表/顺序：先解决"学习去学习"→ 智能的奇点（自我迭代）→ 具身智能。
- 这是"最轻松"的路线图：每一步要新做的东西很少，"可以不用加班"。如果反过来先做具身智能，会做得很累很苦。到后面可以用前面的技术帮助开发后面的技术——奇点之后再做具身智能，就不用人来做了，模型自己就可以做出来。
- 每个人观点不一样，没有对错之分，这只是 DeepSeek 认为最理想、最轻松的路线图。

六、做什么、不做什么：只做 AGI 主线

- 对外打交道的态度：**只做 AGI 主线**（GPT、CoT、Agent 等）。
- AI 领域很广泛，不在主线上的不做：
 - **3D、视频生成**：跟智能主线没有太大关系，不做。视频生成刚出来（Sora 之后）很火，好像不做就不是 AI 公司，大公司小公司都做，但小公司后来都砍掉了——它跟智能上限没有关系。商业上它是个好生意，但 DeepSeek 不会因为是好生意而做，只会因为它在智能路线图上才做。
 - **世界模型**：含义没那么清楚（很多东西都可以叫世界模型），判断是现阶段跟智能上限没有太大关系，不做。当前最重要的是把 AI 训练做好，训练做好并不需要世界模型，甚至不用多模态——缩小训练范围只是有一部分任务做不了，不影响算法成立。
- 路线图：现在最重要的是训练 → 下一步解决持续学习 → 再下一步解决它自己问问题。路线图里没有世界模型、没有视频生成。
- **多模态**：一直在做、肯定会做。对产品（尤其 C 端产品）很重要，但对智能上限它是一个**组件**，不是主线本身——跟搜索一样（搜索也是组件）。**V4 及后续版本会支持原生多模态**。
- 其他人做这些方向，DeepSeek 很乐意帮忙（有没有时间、同学感不感兴趣是另一回事），利益上没有冲突。
- 希望 AI 技术用到各种生产环境、提高社会和各行各业的生产效率，非常有动力做这个事情，且认为这与商业没有任何冲突——该拿到的利益不会少。
- 秉持这种态度并没有少拿任何东西：没有因为开源、善意、帮助别人而受损。去年的 C 端用户现在还比较多、比较稳固；今年 B 端也比较乐观。"反而可能还有加分。看起来违反直觉，但确实如此。反过来想，违背它我能拿到更多东西吗？没有。"
- 很愿意协助任何人做得更好，**包括竞争对手：阿里、智谱、月之暗面**。开源本来就包括把方法尽可能说清楚、希望你能复现；复现不了就告诉你怎么复现，不会因为是竞争对手就不说。如果是合作伙伴，会做更多。
- 一直非常克制，**不愿意跟任何一家互联网大厂或小厂成为对手**，希望给他们赋能、协助大家。

七、核心利益：团队稳定性

- 在很多方面都非常克制，但核心利益只有一点：**保持团队的稳定性**——最大的核心利益，甚至可以认为是唯一的核​​心利益、唯一没法退让的东西。
- "只要能保持团队稳定性，就一定能做成 AGI，就这么简单。只要大家都不走，遇到挫折也可以继续，基本上没有什么风险，只是早一点晚一点。"

- 钱不是问题、资源不是问题，其他要素都容易获得；其他问题最多导致晚半年、晚一年，不会做不出来。
- 团队不稳定是最大的挑战/风险。**这个风险随着近期这次融资得到了较大解除**——大家拿到的期权比较多、金额比较大。
- 只要最重要的、最老的员工稳定，其他人不太会走；哪怕期权少一点、收入少一点也不会走，因为大家不是全奔着钱来的，都希望在能做成 AGI 的环境里做事——对人才有吸引力。
- 历史上 DeepSeek 人才流动跟同行比一直是比较少的，但这依然是最大、唯一的挑战。
- 现在做的很多事情都是为了保持团队稳定性；除此之外其他都可以不要、可以克制。

八、与美国的差距：资源（算力）

- 跟美国的差距只有一点：**资源**。卡的数量比较少。
- **现在大概是两万张 H 等效算力**，其中大部分最近一两个月刚到，可能还有很多机器没来。去年总算力比较少，今年在非常激进地扩充。接下来几个月还会有大批量机器买进来，**基本上都是英伟达**。
- 需要多少卡？越多越好，毫无疑问。策略是：**在合理的价格里，能买到多少就买多少**。花钱的速度不在计划里——只要价格合理，有多少买多少。
- "如果半年之内把（融资的）钱都花完，那太幸福了、太理想了。"实际上很难：买不到那么多卡，很难买、价格也高，还得确保价格合理。愿意付一定的溢价把钱变成卡，"因为这太划算了"——钱放银行大概两个点利息，买英伟达卡是十个月（回本）的社会成本。哪怕付完溢价也很难实现目标。
- "如果今年能花掉两百亿，那属于采购部门业绩超级好了。"
- 买了卡之后，通过提供服务总能有现金流，有现金流就可以活，不需要账上放很多钱。只担心买不到那么多卡。

人才没有差距：

- 人的差距几乎没有——就是同一批人（中国人），出国留下比较随机，并不是聪明的人都去了国外；最聪明的那批人可能一半多一点在国外、一半少一点在国内。国内人才不缺，基数大，每年有大量补充。
- **人才不是瓶颈，资源是最大的瓶颈**。资源影响人才培养：算力少、实验机会少，所以人才整体上与美国有差距——**人才的差距本质上也是算力的差距**。
- 所有看到的区别（人才、模型能力、应用）都可以认为是算力资源上的区别。
- 算力差距的两个原因：国内本身买不到卡；资本投入比美国少很多。人才工资在其中占比很低——他们开一亿美金薪水，但算下来人才薪水占比仍然很少，大头还是算力。

模型规模差距：

- 现在最大的模型（美国）激活大概 **800B**；国内还在**几十 B** 激活的规模——差一个数量级。
- 在最大的模型上"我们其实训不起，哪怕把五百亿全花掉也训不起；哪怕堆起来也用不起"。
- 要训跟美国同样大的模型，需要**五万张 GB300，或者华为 950 二十万张**——这只是训练，还没考虑做研究。这个问题目前基本无解，因为华为产量也有限。

- 现在根本不会考虑在这么大的规模上跟美国竞争。当前策略：先在训练得起、用得起的几十 B 激活规模上做好、做更多实验（这个规模还有很多实验要做、很多事情要搞清楚）；等有更多资源，再做到 150B、156B 或 250B 激活的规模。离能训 800B 还比较远。
- 硬要训那么大的模型也能训，但训之前没法做充分的研究。

九、大模型竞争的终局差距

- 大模型竞争到终局，可能没有太大差距。最终差距体现在三方面：
 1. **成本**（排第一）：提供同样质量的服务，能以什么成本提供。类比亚迪的电池——同等技术下别家能不能按这个价格提供，这是比较难的事情，肯定是壁垒。
 2. **时间**：什么时候能做到，早几个月晚几个月就不一样。
 3. **用户体验**：会有一些用户粘性和用户壁垒，但可能不本质。
- 本质还是成本第一、时间第二（做同样的东西，快一点还是慢一点）。
- 比较模型效果必须在**相同成本**上比较才有意义（就像比较两辆车要同价位比较）。做得好与做得差的模型，差别不在某个具体环节，而是整体上的。

十、商业化节奏

- 现在最值得做、最值得花精力的还是 AGI——把智能的上限往前推。这在现阶段比做更多产品线、考虑更多商业化路径收益更大。"在未来的一段时间，以及过去的任何一段时间，可能都是这样。"
- 花很多时间思考丰富产品线没有用。半年前讨论出来的商业化（做广告、做电商、植入电商、结合本地生活）肯定没用，**因为变化太快**，产品生命周期很短，你并不能预见未来，能预见的很少。
- "在过去三年，任何一个时候你来跟我说商业化路径、产品线，都是浪费时间。"
- "**我们一直在做商业化，只是没有以商业化为目标。**" 以 AGI 为目标，但一直在做商业化，所以才有 C 端用户、B 端收入。从历史经验看这个策略是成功的。
- 离彻底转向商业化的时间点应该很遥远。最大的（收益）还是技术的延伸、做下一代技术。"在现在能看到的未来，任何一个时候聚焦在产品上都太早了。"
- 这也是克制的一部分：希望商业机会让其他人来做，让整个社会、所有合作伙伴一起做、一起分享收益，而不是独吞——不可能独吞，而且也没有那么多精力和人。

C 端 / B 端是副产品：

- AGI 路上必须经过（互联网智能上线）这个台阶，把这些技术通过 API 给大家服务，没有干额外的事情——**API 是做 AGI 的副产品**。"只要搞几个人维护 API 就可以了，甚至客服都没有，也不用销售，用户自己就会来。"
- C 端和 B 端都是做 AGI 路上的副产物、中间产出，跟做 AGI 没有冲突。不是为了做 C 端/B 端而做模型（其他公司是为了服务用户而做模型），DeepSeek 的初衷是追求 AGI，刚好产出这些东西就拿来商业化。
- **这在一定程度上是降维打击**：站在技术高位做相对低一级的技术。AGI 是更大的愿景，能凝聚更多优秀的人、凝聚力更强，所以在组织上有优势。

- 商业公司的愿景是服务好 C 端用户，那是另一个故事：它在产品、用户服务、流量上有优势，但技术上没有优势。而现在比较有利的形势是**模型技术是最重要的**。
- 去年春节突然火"不在我们的剧本里，完全没有想过"，只是想把技术做好。但那时发现：相对完全商业化、以产品为目标的组织，DeepSeek 在人才跟组织上有额外优势。"C 端大家抢得头破血流，结果被一个没有去抢的人牵走了"——印证了这个逻辑。
- 人才优势不是人更聪明，而是**怎么组织、怎么激励、怎么合作**。聪明人聚在一起并不会自然而然合作、有激情地奔向一个目标，需要一个愿景。"AGI 这个愿景是很强大的。"
- 在 C 端没花很多力气，甚至一度不想维护那些用户了，"但用户赶都赶不走"，最终都还在。今年 B 端收入增长比较乐观，跟同行比应该也比较好，但并没有花很大精力，"就是顺便做的"。

十一、决策机制与组织管理

决策机制：

- 公司整体建立在**共识**的基础上，不是梁文锋一个人决定所有事情。他在公司内的权威和影响力建立在共识的基础上。
- 做一件事先看大家的共识是什么、想不想做；可能会有一些引导或倾向，但引导的作用非常有限。一定是有共识才推得下去、才会去推。
- 目前梁文锋的主要精力基本都在 DeepSeek 这边。

管理的两条线：

- **自上而下 ("正式")**：集体做一件事，需要全公司配合，比如发 V4 就得分工，每人做一部分。
- **自下而上**：每个人自己想做什么自己做，没有人管，没有 KPI，可以按自己觉得重要的方向自由探索，没有前置要求。只要公司算力能支持（或者他需要的很少），根本不用协调。
- 标准："正式"**最好不要占用员工一半以上的时间**，另一半时间不被安排、想做什么做什么。
- 有人觉得 DeepSeek 是自上而下的，有人觉得是自下而上的——两个都对。

不加班的两个原因：

1. 做研究需要比较松弛的环境。逼得很紧就没法做研究——研究要靠自己的兴趣、平时自己去想问题。
 2. 非常聚焦，要做的事情很少，就不需要加班。
- 这跟克制一脉相承：因为克制，很多事情不做，每个人分到的工作就少。"你看我们的产品很多都不完善，我们也没有去补它。这也是我们的一种文化。"

融资与合作伙伴：

- 这次融资（对象）是**精心挑选的**：跟 DeepSeek 利益最一致、最没有敌意、最希望 DeepSeek 能做成功的。"不是所有人都希望我们做成功，因为我们还是损害了很多其他人的利益。"

十二、行业竞争格局判断

- **Anthropic 现在超过 OpenAI 不是长期的**，肯定是阶段性的。OpenAI 和 Google 未来大概率还是会交替上升。

- Anthropic 在 Code Agent 上的优势没有那么大，并没有碾压 OpenAI。"我们公司可能有一半的人平时觉得 OpenAI 更好。" Anthropic 有先发优势，但先发优势应该很快就没了，不是能长期占得住的优势。
- 这三家（OpenAI、Anthropic、Google）都很厉害，效率是最高的，花掉/烧掉的钱应该是最少的。
- **全球 AI 分工中，中国公司很可能扮演产量最大的角色：**产能最大（包括芯片产能可能最大）、电力最多，"我们的 AI 最终很有可能是三体之一"。
- 中国人会把这个产品做到最便宜，效果上跟美国差别不大（类比其他商品：中国产与美国产区别不大但更便宜）。**中国产 AI 的便宜可能是系统性的低**，跟其他行业中国提供的服务更便宜一样。
- 做事的思考习惯："我现在这个时候做什么收益最大？"显然现在做产品不是收益最大的，做 AGI 才是。

十三、国产芯片与英伟达生态

CUDA 护城河正在被快速瓦解，原因有三：

1. **有了 AI：**AI 可以写代码，建立生态比以前容易很多，可以用 AI 构建出跟英伟达一模一样的生态。
2. **新技术，如 DeepSeek 自家的 TileLang（一种高级语言）：**用它写 CUDA 算子，可以很快把英伟达整套生态全部重写一遍，再结合 AI，看起来没有什么障碍（还没完成，但技术路线看起来没有障碍）。
3. **专用芯片趋势：**CUDA 是从游戏卡演变来的、兼容游戏卡。以前 AI 计算是小领域（比游戏卡市场小），耦合是合理的；现在计算卡市场已经比游戏卡更大，没有理由再耦合。以后不管华为还是英伟达自己，都是专用芯片。专用芯片跟 CUDA 不绑定，芯片设计时就已考虑怎么建生态——原来英伟达生态的作用大幅减少。

国产芯片的历史性机遇：

- 之前国产卡适配的难题是"生态不好"——买了卡用不起来，没有英伟达那个生态，所以英伟达护城河很强。但这正在变化。
- **判断：未来一年之内能看到"国产芯片的生态完全没有问题"被验证**，会用事实扭转认知。国产 AI 芯片硬件和生态都没有问题，**唯一的问题是产能不够**。
- 国产卡适配没有障碍，英伟达挡不住。在正常商业环境（能买到英伟达卡）下国产替代比较难；但在买不到英伟达卡的情况下，所有人迫不得已都要做国产芯片——这个背景下国产卡适配没有任何障碍。国产卡建立起跟英伟达一样、甚至更好的生态没有障碍，但需要时间。
- "我对国产算力比较乐观。在这一点上，**英伟达是在掘自己的坟墓**。"

与华为的合作：

- 现在主要跟华为合作。华为自己做适配，DeepSeek 会深入参与华为的生态建设。华为的问题还是产能不足。
- **华为给 DeepSeek 大概一万六千张卡的产能**（互联网大厂可能是十几万张）——这可能已经是华为的产能极限了。

- 没法指望在华为（卡）上训后面更大的模型（几百 B 参数激活）——今年不行，但明年、后年说不定有机会。
- 华为卡适配上，DeepSeek 主要做的工作是**把高级语言编译器（TileLang）做好**，做好之后问题可能迎刃而解。
- **V3 训练时用的还是英伟达的卡，但已经不用英伟达的生态了**：先写高级编译器 TileLang，基于 TileLang 的生态完成其他所有事情，几乎不依赖英伟达生态。只要把这套过程在华为卡上重做一遍就完成了。"这里可能是一个历史性的使命，可以完全扭转大家对国产卡生态不好的认知。天时地利基本都全了，就差时间。"一年之内应该很多人会明白这问题算是解决了，剩下就是产能问题。

华为 950 超节点 vs 英伟达：

- 华为 950 超节点在性能和价格上**可以完全平替英伟达 GB200、GB300**。
- 价格肯定更贵但贵得有限：贵 50%、100% 无所谓，贵 200% 都无所谓——贵 100% 已经可以认为价格上平替了。
- 任务上也可平替：GB300 能做的任务华为超节点都能做，延时等都一样。
- **唯一的代价：四张华为卡顶一张英伟达卡，同时落后两年**。"落后两年"指：华为 950 超节点是今年 Q3/Q4 的货，英伟达 GB200 是两年前 Q3 的货；英伟达今年 Q3 可能已有新一代。
- 结论：**中美芯片差距，生态上以后不会再有差距，芯片上是"四倍 + 两年"**。

十四、垂直整合与业务边界

- 会不会向上游垂直整合？"我希望不要。"不希望把所有东西都吃了，**只吃一块——最擅长的、自认为最核心的、跟用户直接相关的那一块**。很多产业伙伴比 DeepSeek 更关注（应用等），那应该是别人的意义，不应该由 DeepSeek 来诠释。
- **自建大型集群是肯定要的**，一直在做，所有集群都是自己建的。
- 要不要自研芯片？取决于收益有多大。类比：运营发电厂的不一定要造发电机，只要发电设备价格合理，为什么要自己造？希望能以合理价格买到芯片，就不用做芯片。（提到最近英伟达芯片的利润，不见得可以.....〔原文未尽〕）
- AI 时代会产生很多家万亿级别的公司，"我觉得我们是其中一家"，只做其中一小块已经没有什么问题，并不需要什么都做。
- 至少在 To B、To C 这两个业务上，目前能看到的：真的一心想做 To C 闭环的，反而 DeepSeek 做得好；真的想做 To B 闭环的，说不定也没有 DeepSeek 做得好。"你想要得越多....."（越得不到）。
- **To B 业务的上限是需求，不是算力**。在当前这一代 AI 技术背景下 To B 需求是有限的，会快速增长但不是无穷大，最终受制于需求。十个月就能回本，只要有去处肯定会买（卡），所以瓶颈不在算力。随着技术持续突破，需求会越来越大。
- "最想得到的东西反而得不到；没那么在意的事情反而蛮容易得到。"

十五、Scaling 与下一代模型

- **信 Scaling**：规模越大效果越好、能解锁更多功能。阻止 Scaling 的是算力，不是不想 Scaling。

- 没有触摸到 Scaling 的上限。训现在这么大的模型不是因为够了，而是**刚好只有这么多资源**——按资源倒算能训多大的模型。
- 目前模型（Scaling）收益还是非常明显的，还没机会碰到 Scaling 的墙，“离我们还很远”。**“硅谷说 Scaling 到头，那是对硅谷说的；对中国人来讲我们离那个还很远，根本就没有 Scaling 到那个程度。”**
- Scaling 包括数据的 Scaling、模型规模的 Scaling、训练成本。会不遗余力推进 Scaling 上限；融资完成后有更多算力，可能训练更大的模型。
- **下一代模型的核心能力：必须要有持续学习的能力，才能叫下一代模型。** 在那之前能做的是：成本（更低）、效果更好、速度更快；但大突破必须具备持续学习。

十六、为什么特别在乎计算效率

- 不是所有人都在乎模型效率。商业化公司没有动力追求极致的模型效率——“低成本了，你还赚什么钱？低成本了，你就收不到什么钱了。”几个创业公司自己不会说低成本是追求，因为不符合他们的利益。
- 对 DeepSeek，**低成本是愿景的一部分**：同学们都是普通人，知道用这个要花钱，有同理心——便宜一点，别人接受程度更高。很多同学希望把成本做到更低。从商业角度讲不会这么考虑，成本不是第一优先级；对创业公司和大公司来说这个服务成本根本就不高。
- 希望它是比较轻的、负担得起的，**特别是在中国算力紧缺的背景下**，能在国产卡上用。
- 低成本首先是一个结果：模型架构一直往更低成本方向走，这跟愿景有关系。算法上还有很多方法，成本还可以往下走。
- 另一个原因：**成本越低，越能训练/承担更大的模型。**在算力有限的情况下，计算效率更高就能承担更大的模型。大公司不一定这么考虑（资源可以加），但 DeepSeek 会优先考虑成本效率。
- 数据的价值：数据范围比较广，**数据应该几乎等于模型的一半。**

十七、“拿多少”的宏观逻辑

- 假设 AI 能占 GDP 的 20%，如果想在里面占 5%，绝对行不通——肯定会被另一个只要占 1% 的人打败；如果又出来一个只要 0.1% 的，又会把前面的打败。
 - OpenAI 算这个账（占 5%）理论上是能算得过来的，但问题是**他会被愿意只占 1% 的人打败。**
 - 宏观上，不管这百分之几从哪里拿都一样：**拿得多的人会被拿得少的人打败。**甚至不用真的拿到——大家都还没拿到钱、只是愿景，“你愿景是拿得多，你就先输了”，会面临更大的困难。“这个世界就是这样。”
 - OpenAI 一开始觉得真的能垄断世界，实际上会遇到很多挑战者。美国遇到过的挑战之外，未来还会遇到中国的挑战，因为**中国人愿意拿得更少**就可以提供这个服务；在中国，也会有人愿意拿得更少一点。
 - 但最后会有个平衡：拿得太少，公司商业逻辑不成立、活不下去；拿得太多，被拿得少的人打败。
 - 所以 DeepSeek 不追求利润最多、不做收益最大化的定价，只赚一个合理的收益。
 - “我是相信这个事的，并不是为这个事情找理由——我本来就这么做的。这个理由可能不惯常，但我们公司本来就不惯常。”
-

第二部分：问答环节（逐题整理）

Q1：持续学习什么时候带来突破？需要哪些架构、算法创新和关键要素？

- 人少，需要研究。现在全世界都在研究这个问题。投资人现在看到最多的是 Agent，但对做研究的人来讲，现在看到更多的是"学习"、怎么解决学习这个问题。
- **学习可能不是一项技术，它是一个问题。**解决它可能有很多种技术，不是一个东西，会是很多东西。AGI 也是由很多东西组成的：需要模型，还需要很多其他东西。它也是一个工程和算法问题，有很多方法、很多研究。

Q2（某机构投资人，表达对使命愿景的认可，"修己达人"、榕树小鸟天堂"利万物而不争"的比喻）：

Q2-1：开源后行业里有多少伙伴能复现开源成果？生态需要哪些高质量人才衔接？会不会走向"模型矩阵"（基模+垂直行业模型/应用模型）？两三年后生态长成什么样？

- 每个企业都面临人才不够的问题，但**人才短缺是阶段性的**。每个行业发展初期人才都不够：以前做网站、后来互联网做服务端，人才都缺过，但都两三年就解决了，因为会培养出大量的人。十几年前说飞行员很缺（培养周期长），也很快解决了。**历史上从来没有出现过长期缺某一类人的情况**。AI 人才短缺已经看到大幅度缓解，每个公司很快会把人培养出来。
- **国内做（基）模型的公司太多了**。美国可能就三家，中国做基模的太多，资源分散、某种程度上浪费——每一家都做同样的事情，美国资源集中在三家，中国每家拿到的资源更少。**最终一定会收敛**，不需要那么多家。
- 现在大家觉得利润率非常高所以都要自己做；当发现没有那么高利润时可能就不做了。"我不相信有那么高利润，因为不符合客观规律。如果有非常高的利润率，这一定不符合客观规律，应该是一个合理的利润。"
- 如果每家都只拿合理的利润，就不需要那么多人做大模型。**中国最后有三四家竞争就很充分了**（可能两家大公司、两家小公司就比较够了），价格绝对够打价格战。
- 生态上没有太多想法：有意愿扶持更多的人、没有利益冲突、希望合作共赢，但没有那么多精力，有没有去做是另一回事。
- **绝对不认为大模型公司可以拿走大部分利润**——不可能，这么多大模型公司差距不大。差距只有时间和成本两个东西，不至于哪家有暴利：成本控制好的多赚一点，控制差的少赚一点，仅此而已。

Q2 追问：数据方面——到 AGI/模型自我迭代阶段，仿真数据能不能用？还是真实数据质量最高？会不会因依赖人类过往真实数据而限制智能上限？能否通过模拟/仿真/创造数据超越人类过往？

- **能超越**。例如围棋：AlphaGo 下了一手人类从来没见过的棋——它肯定是在一定范围内超越了人类。
- 它可能也有上限、有局限性，但这个局限性现在看不到。笼统地认为：它可以在人类已有的、已能说出来的知识之上予以超越。
- 后续靠真实数据还是仿真数据能否 work？——"（不可能只有一条路，）有很多方法。"

Q2-2：AI Infra——算力千亿美元级投入，中国硬件短板多久能解决？模型进步让算力消耗边际递减（从硬算到巧算）与硬件效能提升是否相向而行？现在按当前的卡（960/H200）建万卡集群，按三年摊销，实际生命周期如何？三年后会不会变成不先进的冗余算力？

- 英伟达的卡基本可按五年折旧；华为的卡最多按三年折旧。华为 950 今年用挺好，明年用还可以，再往后用"可能就真的太费电了"。华为卡生命周期会短一点，因为本来就比英伟达晚两年，但差距没那么大。
- B200 现在能买到多少都划算。对腾讯、阿里巴巴来讲，如果合理价格能买到，肯定都是划算的——但相信买不到（不是算成本的问题）。
- 算力落后是事实，通过三方面消解：第一，承受一定的模型落后、模型尺寸更小；落后也有好处——落后意味着有更多时间、有一定的（成熟）技术，可以用巧妙的方法。
- 当前叙事：落后美国约 12 个月（12–18 个月，或 6–12 个月；简单说落后两年），但只用美国二十分之一的算力把事情做出来。
- 未来目标：改写叙事——仍用几分之一算力，但把时间差缩短到 6 个月、3 个月。甚至在某些方面超越他们：总算力有数量级差距的情况下全面超越不现实，但在某些重点、有取舍的地方实现超越是可能的。

Q3：持续学习（国外热点叫 Recursive Improvement）技术上最大的难点是什么？什么时候能解决？为什么"先持续学习、再通用智能"？背后的技术根源？解决持续学习后 DeepSeek 会做通用智能吗？

- 难点在于现在还没有找到非常 **work** 的方法，全世界都没找到，大家都在摸索，不知道谁能摸到下一个解决方法。有很多思路、很多现在看起来有前途的想法，但都还没做通。
- 内部比较看重的叙事：训练下一版模型，希望它能帮助 DeepSeek 自己的开发、提升 DeepSeek 自己的效率。"我们做的模型，第一目标不是大家用得好用，而是我们自己用得好用。首先对我们自己有用，开发下一版模型时就会更快。"
- 当自己好用时，意味着别人可能也好用，但首先保证自己好用。"这个叙事有点奇怪，但确实很多人就是这么想的。"逻辑是：**这是实现 AGI 最快的方法**。现在非常确定：确实需要人工智能来帮助实现 AGI——虽然它还不是自主工作、还只是跟人搭配，但已经很有用了。
- 为什么先持续学习再通用智能：解决持续学习可以大大加快研发进度。先解决了持续学习，通用智能就不在话下——有了能持续学习的 AI 辅助，它的能力非常强。现在 Agent 能力受限就是因为不能有效持续学习。持续学习先做出来，用它来做通用智能就很容易、很省力、很轻松；否则人工去做通用智能是比较累苦、数据密集、人力密集的事情，性价比不高。

Q4（线上聊天区问题）：AGI 还需要多久？国内硬件在这个时间内能追上吗？

- 关于华为 950：华为现在给 DeepSeek 一万六千卡（这应该是可以公开说的），比互联网大厂少一个数量级；华为也只能给这么多，价格也不便宜。互联网大厂需求更大、更需要。DeepSeek 可以买一些不合规的卡，所以买华为 950 的目的还是希望帮华为把生态做好。
- 一万六千卡的华为 950 只相当于四千卡的 B 系列，不是很大的量、意义不是很大：不够训下一代模型，只够训现在这一代模型，但可以让华为先把（生态）做好。
- AGI 多久：在 AI（不是 AGI）这件事上，按现在的方式/范式，国内一两年能做到跟国外差不多，或者今年就能做到平替国外的模型——不是很难的事。但那还不是 AGI；AGI 至少得能够持续学习。
- 国产硬件：可能需要几年时间。先解决生态问题（生态是一个信心问题），再解决产能问题，应该能逐步解决。"今年、明年、后年可能都还卡在产能问题上，但我不太相信五年之后还卡在产能上，我还是比较乐观的。"

Q5（线上）：未来的组织架构、人员规模规划？

- 之前的组织架构非常分散（因为没有组织架构）。人员进一步扩大之后肯定需要改变，需要做很多改变，现在很难一下子全部表达。
- 最后应该还是分不同的部门：**有些部门需要建立比较严谨的层级结构，另一些部门维持比较松散、扁平的结构。**
- 随人员增加会做调整，“马上就得做，我已经在做这个调整”——不说的话很多事情没法推进，确实有很多部门应该有组织架构。

Q6（线上）：版本节奏与规模对标

- 现在线上发的 GCV4（V4？原文如此）这个版本还比较粗糙，能力方面很多还需要时间。
- **比较舒适的发版节奏：大概两三个月发一版。**上次发版可能是四月底，下次可能是六月底。如果没有意外，会一版比一版好。
- **在 50B 激活的尺度上，最终跟现在这波开源（模型）不会有太大差别——推理速度跟效果上可能不会有太大差别。**
- 但跟（美国）那个没公开的大尺寸模型差距还比较大，这个激活参数做不到，得是更大尺寸的模型，比如 **150B**。按现在训练进度，**乐观的话今年年底可以开始训 150B（至少到明年.....）。**“对，这是跟 OCE（原文如此）的差距，差距还是比较大的。”

Q7：AGI 是渐进过程、不会突变——可以理解为没有临界点吗？

- **没有临界点，但它是非线性的。**比较相信的叙事：**AI 可以加速 AI 的研究。**因为可以用 AI 加速自己的研究，所以到后面可能是非线性的。

追问：所以语言模型继续 Scaling 是足够的？

- 只能说语言模型的 Scaling 现在没有看到上限——“我们现在的智力水平，或者说美国的智力水平，都没有看到上限。”

追问：美国 800B 激活的模型训得起但也用不起/很难拿出来给大家用（太贵）？人类拥有语言能力只有近十万年，前面进化了三十七亿年——训练 AI 顺序可以反过来，但最终还是要进入物理模型/具身那部分？

- 对，具身肯定还是要进入，最终是具身。对公司来讲，自然而然终点都是具身。因为对一个正常人来讲，他的需求并不是电脑——正常人吃喝玩乐、衣食住行不需要电脑，他需要具身智能来解决具体人力的需求。如果目标是解决人力需求，具身绕不过去。

追问：到了可以自进化的时间点，希望这个状态的 AI 落地的第一个（应用）是什么？

- 可能跟现在不一样。如果没有具身，对 AGI 的定义/希望它做的是：**帮我们迭代下一版模型。**有了具身之后，希望它做的也是：**让它来迭代下一版的具身、做下一版机器人。**

追问：之前采访提到重要方向选择靠品位和直觉，不是简单工程优化。如果 AI 能自进化，品位（taste）、直觉还重要吗？重要的会是什么？

- **“AI 现在不缺品位和直觉，它缺的是持续学习的能力。”**AI 的品位和直觉没有问题——让它写篇文章，品位和直觉没什么问题。

Q8（屏幕留言）：持续学习是未解决的研究问题，而 coding agent 追上（MILES/Office/MIS 水平，原文识别不清）是较确定的 Scaling 目标。研究资源、研究员人才如何在两者间分配才能达到最好平衡？

- 模型（追上）Office 是比较确定的目标；模型（追上）MIS 还不好说确定，只能说是一个目标。
- **（持续学习这类研究）不占资源：**"CoT 不占资源"——做这类前沿研究不消耗卡（只需要很少的卡），需要的是想法；也不消耗人才资源，因为不需要有人一直在那里做。它不是一个项目，而是需要很多人都在那里想这个问题。
- 训模型、发模型、做模型的效率实验才需要资源。
- 内部把这类探索叫**"摸奖"**：门槛很低，谁都可以去摸，但谁能摸出什么来，"我也不知道是看天赋还是看什么"。
- 不需要分配资源，只是 DeepSeek 跟其他公司不一样的地方在于：**会花时间去讨论、去想这个问题，把它当做重要的事情——是重要的、会花时间思考的问题，但不需要花很多资源去做。**

Q9（屏幕留言）：大模型幻觉问题比较影响用户体验？

- 幻觉问题是有方法解决的，但是一个长命题。**可以认为是能通过更好的 Post-training 解决/改善的问题**，只是大家没花很大力气去做。
- 对 DeepSeek 来讲，幻觉是一个问题，但归结起来可能是**产品问题**——会去解决它，但不是重点问题。

Q10（屏幕留言）：数据标注问题

- 数据标注跟资本投入（结构）有关：以 DeepSeek 的资本投入结构，**支撑不起那么多高质量数据标注的成本**，因为成本很高。
- **美国和中国的数据标注成本没有什么区别**——中国标数据并没有成本优势，尤其标高端数据上没有成本优势，所以很难像美国那样投入标数据。这条路在中国很难，标数据实在太贵，外标还是自己标都很难受。
- 现在基本是**两条腿走路**：不是完全不标——标数据有些成本低、有些成本高，**先标成本低的**。
- "你也可以认为，现在我们公司有一半的人在标数据。有一半的核心研究员、最重要的人，有一半在标数据。我们就集中在标数据。**解决 AI 这个问题，在现在这个阶段靠的就是标数据。你只要看，就是一个数据（的事）。**"

Q11：中国模型除了效率，未来还有哪些方面可能比美国强？

- **体验方面**有可能比美国做得好——用户体验不一定比美国差；**产品能力**上不一定比美国差；**成本**应该也比美国低。所以中国还是会有竞争力的。
- 其他方面如果说有结构性优势，可能也没有；但**成本和产品这两方面确实有一定的结构性优势**。
- 成本的结构性优势很好理解：他们（美国）不用做（低成本），所以就不发展这个能力，他们肯定没有我们重视这个事情——对我们是非常重要的事情，对他们不重要。产品也是，（中国）原生有很多公司，产品能力还是可以的。

Q12：后训练投入——Anthropic、OpenAI 投入巨大，融资后会加大后训练投入吗？

- 差距主要在**高质量数据的标注上**，主要在 AI 研究里面。肯定会加大投入，但高质量数据标注典型地不是资本投入（问题）。

- 高质量数据标注的瓶颈是**时间**。OpenAI、Anthropic、国外都起步更早、资本更多、卡也更多；国内可以认为最近半年才开始做，所以需要更多时间。
- 跟资本投入关系不大：哪怕没有更多资本投入，原来的资本也够它以最快速度扩张了，但这个速度有上限——不卡在钱上，也不卡在卡上，就是需要时间（不是马上能有更多的人）。它确实在快速扩张的过程中。
- **预期：一年之内，国内高质量数据这个问题能做得比较好。**“面可能没有那么冷，但确实需要时间。”

Q13: Anthropic 用自己的模型做垂直产品（金融、法律，未来医疗），DeepSeek 某个阶段也会考虑纵向应用吗？

- 还没想得很明白国内的商业模式是怎样的、最顺利的路径是什么，还没到那个阶段。国内外情况不一定一样，国内到时候什么样现在比较难判断。
- 以目前情况看，**最合理的做法是全力做通用的 Agent**；其他 Agent（包括金融、医生这些）优先级更低。
- **要先做 Coding**：Coding Agent 能够做到很多（事情），还能带动很多垂直的 Agent。**现阶段最重要的应该还是 Coding Agent。**

Q14: 纯粹科研/纯粹做 AGI 与资本市场（未来上市、公众股东）之间怎么平衡？

- “我现在觉得应该是能够做到的，就都要。”
- 如果今年能有**几个亿美金的 B 端收入**，加上 C 端有用户，本身已有一定商业基础。明年 B 端有收入、需求再增大的话，**公司离净利润已经不远了，可能就已经是净利润了**——可能已经不是纯烧钱的阶段，后面能操作的动作还是比较大的。
- **保底方案：最坏情况全力卖 API，可能都能支撑一个上市公司。**如果技术后面没有新进步、技术冻结在这里，那就全力卖 API、把服务做好，“我觉得也够的”。
- “还是有信心的，确实没有那么难——在一个杠杆高的地方，又在一个发展非常快的领域。我们希望有更大的梦想，但也有保底可以拿出来的业绩。”

Q15: DeepSeek 的组织形式有学习对象吗？比如历史上的 Bell Labs？还是要靠自己探索？

- **没有模仿的对象。**每一步都从实际情况出发、实事求是、根据实际情况做决策。组织形式是时代的产物、现实情况的反应，不是模仿的结果。
- 跟美国几家公司肯定都不一样（那三家自己也不一样，但他们至少从商业公司的角度出发探索）。每一步都是思考过、分析利弊后选的，不是看到谁这么选就这么选。未来也一样，不会模仿谁，只能靠自己探索。
- **跟 Bell Labs 不一样：**Bell Labs 明确不需要商业化；DeepSeek 明确要有商业化——“我们最终还是要能活下去，我们毕竟是一个公司，**政府不会给我一分钱。**”
- 可以有非常远大的使命，但归根结底是一个公司，要考虑怎么活着。**B 端对公司肯定是重要的，因为以后可能得靠它活着**——只是现在不重要，现在它是个成本线。
- 历史上很多公司也有利润以外的追求，但不能说有利润以外的追求就不是公司。很多公司做得很伟大，正是因为有利润以外的追求——那个追求最后不但没影响商业化，反而让它商业化得更好。“我们本质上还是一个公司，只是在考虑赚哪些钱、什么时候赚钱、赚多少钱、靠什么赚钱上，我们有取舍。”

Q16: 两个技术问题

Q16-1: MILOS（原文如此，识别不确定）不是很确定的目标但会往这个方向做；下一代激活参数 **150–250B** 左右，是对标 **O4.7**（原文如此）还是别的？

- （原文此处未见直接回答，话题转入第二问。）

Q16-2: 推理（inference）上用 **CUDA** 以外的编译语言（原来基于英伟达生态可能用 **PTX** 较多，现在用 **TileLang**），会不会大幅降低或短期降低推理效率？编译语言变化带来的效率损失怎么看？

- "是提高效率，是大幅提高效率。" 没有什么负面影响。
- 这是一个机遇：以前离不开 **CUDA** 生态，现在可以抛弃它的生态，用更简单的方法（**TileLang**）。它是高级语言，写程序很快、代码量很小，"我可以把它重写一遍"。
- 这是技术发展的大机会，不只是 **AI** 的机会——"我们还有一个项目，在用 **AI** 来写 **TileLang**。"
- 目前所有 **TileLang** 都是人写的，但已经比原来写 **CUDA** 快很多了。
- 对硬件底层执行效率的影响：**损失 1% 到 2%，可以接受。**

附录：关键数字与事实速览

项目	数字/事实
API 定价逻辑	买设备 10 个月收回成本 $\approx$ 6 倍利润；财务按 3–5 年摊销；未来利润可能降到 4 倍、3 倍
DDCP 降价	降到原价的 1/4，公司群欢呼
竞对成本	阿里/腾讯的成本应比 DeepSeek 高好几倍
AI 市场规模假设	AI 最终可能占人类社会 GDP 约 10%（另一处假设 20% 用于"拿多少"推演）
当前算力	约 2 万张 H 等效，大部分近一两个月刚到；今年激进扩充，后续大批量采购，基本都是英伟达
花钱意愿	半年花完融资最理想；今年若能花掉 200 亿属采购业绩超好；愿付溢价买卡；银行存款约 2 个点利息
美国最大模型	激活约 800B；国内约几十 B 激活，差一个数量级
训 800B 所需	5 万张 GB300 或 20 万张华为 950（仅训练，不含研究）；哪怕花掉 500 亿也训不起
下一步规模	先做好几十 B 激活；再到 150B/156B 或 250B 激活；乐观今年年底开始训 150B
当前发布版本	GCV4（V4）较粗糙；发版节奏两三个月一版；上次约四月底，下次约六月底
50B 激活尺度	与当前开源模型在推理速度和效果上不会有太大差别；与美国未公开大模型差距大
ARR 展望	今年 API/AI ARR 做到几亿美金很有可能；做到 10 亿美金则现金流回正、cover 全部费用；明年可能接近/达到净利润
华为合作	华为给约 1.6 万张 950 产能（互联网大厂十几万张，差一数量级）；1.6 万张 950 $\approx$ 4 千张 B 系列；只够训当代模型；目的是帮华为做生态；可以买一些不合规的卡
华为 950 超节点	性能/任务上可平替 GB200/GB300（延时一样）；价格贵 50%–200% 都可接受；代价：4 张华为卡 $\approx$ 1 张英伟达卡 + 落后两年（950 为今年 Q3/Q4 货，GB200 为两年前 Q3 货）

项目	数字/事实
芯片折旧	英伟达按 5 年折旧；华为最多按 3 年（950 今年好用、明年还行、之后太费电）
中美芯片差距结论	生态上以后不会再有差距；芯片上是"4 倍 + 2 年"
TileLang	DeepSeek 自研高级语言；V3 用英伟达卡但已不用英伟达生态；重写整套生态；比写 CUDA 快很多；底层执行效率损失仅 1-2%；有项目用 AI 写 TileLang（目前全人写）
CUDA 护城河瓦解三原因	① AI 能写代码重建生态；② TileLang 等新技术；③ 计算卡市场超过游戏卡，专用芯片与 CUDA 解耦
国产芯片判断	一年内验证"国产芯片生态完全没问题"；唯一问题是产能；今明后年卡产能，5 年后不一定；国产硬件整体需几年
中美整体差距	落后约 12（6-18）个月/简单说两年，但只用 1/20 算力；目标：仍用几分之一算力，把时间差缩到 6 个月、3 个月，某些重点处超越
人才	中美人才几乎无差距（最聪明的人约一半多一点在国外、一半少一点在国内）；人才差距本质是算力差距；AI 人才短缺是阶段性的（约两三年缓解）
数据标注	中美标注成本无差别，中国无成本优势；先标成本低的；约一半核心研究员在标数据；瓶颈是时间不是钱/卡；预期一年内国内高质量数据问题解决较好
行业收敛	美国基模 3 家；中国基模公司太多、一定收敛，最后三四家（约两大两小）竞争就很充分
竞争格局	Anthropic 超 OpenAI 是阶段性的，OpenAI 与 Google 会交替上升；Anthropic 在 Code Agent 无碾压优势、先发优势很快消失；公司约一半人觉得 OpenAI 更好；三家效率最高、烧钱最少；中国 AI 大概率是"三体之一"，靠产能最大、电力最多、系统性低价
大模型终局差距	① 成本（第一）② 时间 ③ 用户体验（不本质）
组织	无组织架构、愿景驱动、无 KPI；"正式"（自上而下）≤ 一半时间；不加班（研究需松弛 + 聚焦事少）；扩张后将分部门调整（部分层级化、部分保持扁平），已在做
核心利益	唯一核心利益是团队稳定性；融资后期权较多，风险较大解除；人才流动历来比同行少

项目	数字/事实
融资对象	精心挑选：利益最一致、最无敌意、最希望 DeepSeek 成功的
技术路线	阶梯：语言模型 → CoT（去年）→ Agent（今年）→ 持续学习 → 自我迭代"奇点"（实为渐进、非线性：AI 加速 AI 研究）→ 具身智能
下一代模型定义	必须具备持续学习能力才叫下一代；此前只能做成本更低、效果更好、速度更快
不做的方向	3D、视频生成（好生意但与智能上限无关）、世界模型（现阶段）；多模态/搜索是"组件"，V4 及后续支持原生多模态
Agent 策略	全力做通用 Agent，现阶段最重要是 Coding Agent；金融、医疗等垂直 Agent 优先级更低
幻觉问题	可通过更好的 Post-training 改善；归为产品问题，非重点
品位与直觉	AI 不缺品位和直觉，缺的是持续学习能力
"摸奖"	持续学习类前沿研究不耗卡、不耗人力资源，需要的是想法；门槛低谁都能摸
To B	上限是需求不是算力；需求会随技术突破越来越大
保底	最坏情况全力卖 API 也能支撑一个上市公司
会议纪律	主持人提醒：卡量等敏感数字勿外传，勿录屏分享

注：原文为语音转写稿，个别名词如 "DDCP""GCV4""OCE""MILES/MILOS""O4.7""Office/MIS 水平""960" 等可能存在识别误差，整理时按原文保留并标注，请以原录音为准。